

# KuaiRand-1K 长序列受治理研究：主报告

汇报日期：2026-08-24 (Asia/Singapore)

研究问题：`candidate_long_view_prediction`

当前工程候选：`NEW_BL2 + v012 calibrator`，状态为 *pending new-data confirmation*

这份文件是什么。本文是面向人的主报告：带图、按论证顺序组织、数值统一保留 4 位小数。

同目录的 [...full-report\\_v012.md](#)

是完整档案，保留全部字段级大表、逐条制品链接与 Agent 集成章节，作为本文的附录使用。

两份文件的数值同源，都以各阶段的 `final_decision.json` 与哈希制品为准。

## 阅读路径

| 你是谁                | 读什么                                                                                      | 用时    |
|--------------------|------------------------------------------------------------------------------------------|-------|
| 想快速知道结论有多硬         | <a href="#">§1</a> + <a href="#">图 1</a> + <a href="#">图 2</a> + <a href="#">§7</a>      | 8 分钟  |
| 要判断方法站不站得住         | §1 → <a href="#">§4</a> → <a href="#">§5</a> → <a href="#">§6</a> → <a href="#">§7</a>   | 25 分钟 |
| 要复现实验              | <a href="#">§3</a> → §6 各节的合同链接 → <code>kuairand-longseq-agent/PROJECT_HANDOFF.md</code> | 另计    |
| 要接 NanyangYS Agent | 完整档案 §11（本文不重复）                                                                          | 10 分钟 |
| 要核验证据链完整性          | <a href="#">INTEGRITY_ERRATA.md</a> → <code>python verify_package.py</code>              | 5 分钟  |

不熟悉 `gate` / `post-audit` / `regret` / `tether` 等词的，先看[附录 A 术语速查](#)。

## 1. 结论先行


本研究不试图复现一个可上线的推荐系统，而是回答一个受控的离线问题：

在候选视频曝光的那一刻，只用当时已可见的用户历史、用户静态信息和视频基础元数据，能否更好地预测这次曝光的官方 `long_view` 标签？

答案是能，但每一条结论都有硬边界：

| 层级        | 已验证的事实                                                                                            | 不可越过的边界                       |
|-----------|---------------------------------------------------------------------------------------------------|-------------------------------|
| v010 历史价值 | 冻结 GPU Adam 协议下，加入 H2 严格用户历史的 BL2 相比同静态特征的 BL1，在 Validation、后置 standard 与 random 曝光审计上 AP 增量均显著为正 | 是离线排序增量；不代表线上因果收益，也不代表换优化器仍成立 |
| v011 概率校准 | 目标域截距校准显著降低 Log Loss / Brier，且严格保持排序不变                                                            | 是 post-audit 的时间外测试，不是全新的确认试验 |

| 层级         | 已验证的事实                                      | 不可越过的边界                        |
|------------|---------------------------------------------|--------------------------------|
| v012 受约束适配 | 成对目标域重训练在最终回放上同时提升排序和概率损失，优于 OLD_BL2 + v011 | 同样是 post-audit；上线前仍需新数据确认与人工审批 |



**图 1** 是本研究的主结果。上组三行是同一个对比（ADAM\_BL2 - ADAM\_BL1），覆盖三个逐步开放的数据域；下组一行是另一个对比（NEW\_BL2 - OLD\_BL2+v011），回答的是“重训练还值不值”。两组不能相加，也不能串成一条链——理由见 [§7.1](#)。

- 三件值得单独记住的事：
- 方向一致。** 四个 95% CI 的下界都大于 0，且都超过预注册的最小效应 0.005。
  - random 域的区间最宽。** 它只有 42,372 行，宽度是样本量的直接后果，不是效应变弱。
  - random 域的绝对概率不合格。** 排序迁移过去了，概率刻度没有——这正是 v011 存在的理由。

最精炼的表述是：在本任务、冻结特征、严格时点规则与 GPU Adam 协议下，H2 用户历史有可复现的离线排序价值；目标域校准与受约束适配带来工程价值，但尚不构成线上或因果证明。

## 2. 数据与访问顺序

这一章回答：数据长什么样、为什么这样切、以及“切分有没有被重复使用”。

### 2.1 原始数据

KuaiRand-1K 从更大版本抽取 1,000 名用户，同时提供标准推荐日志与插入的随机曝光。选它而不是更小的 Pure 版本，是因为问题依赖完整、严格按时间排序的行为史。

| 数据域                            | Raw 行数    | Silver 行数 | 在研究中的角色            |
|--------------------------------|-----------|-----------|--------------------|
| early standard (04-08 → 04-21) | 5,055,984 | 4,992,443 | Train + Validation |

| 数据域                             | Raw 行数            | Silver 行数 | 在研究中的角色      |
|---------------------------------|-------------------|-----------|--------------|
| late standard (04-22 → 05-08)   | 6,657,061         | 6,556,501 | sealed 时间外测试 |
| random exposure (04-22 → 05-08) | 43,028            | 42,982    | 独立曝光审计       |
| users / videos basic            | 1,000 / 4,371,868 | 不变        | 静态维表         |

`video_features_statistic_1k.csv` (52 列月内聚合统计) **默认禁止进入同月预测——**  
读它相当于把目标期之后的信息带回当前事件。它从未物化进 Silver，也从未 join。

Silver 清洗不是删行：完全重复行保留一条 canonical、副本进审计；载荷冲突整组进 quarantine；  
`long_view` 公式不一致的记录单独隔离并**同时保留官方标签与重算值**。  
每种问题行都有去向，没有一种“清干净了就消失”。

## 2.2 访问顺序与切分对齐

**数据域、访问顺序与实验切分：v011 与 v012 的边界在行级上精确对齐**  
浅色条为数据域，深色条为该域上实际使用的切分




图 2 是这份研究在方法上最值得说的一处设计，也是最容易被质疑的一处。

质疑通常是：“v012 是不是换了个切法，把对自己有利的数据切出来了？”答案可以逐行核对：

|                                                |                     |
|------------------------------------------------|---------------------|
| random 域 canonical 总量                          | 43,027 行            |
| └ 前置区间 04-22 → 05-02                           | 19,275 行            |
| └ v011: fit 8,731 + selection 10,544           | = 19,275            |
| └ v012: adaptation 11,999 + calibration 7,276  | = 19,275 ← 边界完全相同   |
| └ 后置区间 05-03 → 05-08                           | 23,752 行            |
| └ v011: held-out test                          | = 23,752            |
| └ v012: selection 11,353 + final replay 12,399 | = 23,752 ← 同一区间的再切分 |

由此得到两个可核验的性质：

- 信息量对等。v011 校准器所用数据与 v012 适配+校准所用数据在时间上同界，两个候选看到的历史信息完全相同。§6.3 的对比因此是公平对照，不是“新模型多看了几天”。

- **最终回放从未参与选择。** 05-06 → 05-08 的 12,399 行在 v011 报告之后才被单独切出；v012 的 C1/C2/C3 选择只用 05-03 → 05-05 的 11,353 行。

它的代价也必须写出来：v012 的 selection 段取自 v011 曾报告过的 held-out 区间。这在时序上完全合法（v011 早已冻结发布），但意味着**两轮结果共享数据、不可当作两份独立证据相加**。

**还有一个硬约束：random 域的 43,027 行已被 100% 消耗**，包内没有剩余的随机曝光数据。这直接决定了"待新数据确认"该怎么做——见 [s8](#)。

## 3. 模型与时点规则

这一章回答：三个模型差在哪、"严格历史"到底怎么定义、防泄漏靠什么保证。

### 3.1 三个嵌套模型

三个模型预测同一批候选事件的 `long_view`，**只改变允许使用的信息**：

| 模型  | 组成                                                                               | 这个对比回答什么                     |
|-----|----------------------------------------------------------------------------------|------------------------------|
| BL0 | 冻结的常数概率 $\hat{p}_i = \hat{\pi}_{\text{train}}$                                   | 只报训练期总体正例率时，概率损失的基础参照        |
| BL1 | 静态特征的正则化稀疏逻辑回归（9 个类别 + 5 个连续 + 5 个质量状态，共 19 个字段组）                                | 静态 ID、元数据和质量状态本身能解释多少        |
| BL2 | $\mathbf{x}_i^{(\text{BL2})} = [\mathbf{x}_i^{(\text{BL1})}, \mathbf{h}_u(t_i)]$ | <b>严格用户历史是否在同一静态模型之上带来增量</b> |

BL1 与 BL2 的**唯一系统差异**是那 18 维历史特征（展开后 13,527 → 13,545 列），所以差异可归因于历史，而不是换了数据行、标签或静态特征。

对 BL1/BL2，线性分数与概率为  $s_i = \mathbf{x}_i^\top \mathbf{w} + b$ 、 $\hat{p}_i = \sigma(s_i) = 1/(1 + e^{-s_i})$ ，训练目标是带 L2 的二元交叉熵， $\alpha = 10^{-4}$ ，截距不参与正则。

### 3.2 严格历史：唯一允许的边界是 $t_j < t_i$

对用户  $u$  在目标时刻  $t_i$ ，允许的历史集合是

$$\mathcal{H}_u(t_i) = \{j: u_j = u, t_j < t_i\}.$$

**严格不等式是本项目的核心反泄漏约束。** 对相同 `(user_id, time_ms)` 的多个候选，执行顺序必须是：

- 读取目标时间戳批次
- 用此前已冻结的用户状态，为批内每个候选构造同一份历史特征
  - 预测并保存
  - 才用该批次的已观测反馈更新用户状态

因此批内视频共享用户状态，却绝不能互相看到当前批次的标签、播放时长或点击。  
对 random 目标，状态表**只含 standard 事件**——random 标签不更新任何 H2 特征。

H2 共 18 维：最近 10 / 50 / 200 个历史批次各 4 维（事件数、正例数、平滑正例率、窗口满标记），  
加全历史 5 维与冷启动标记 1 维。平滑正例率为

$$R_{u,t}^{(k)} = \frac{P_{u,t}^{(k)} + \lambda \hat{\pi}_{\text{train}}}{E_{u,t}^{(k)} + \lambda}, \quad \lambda = 20.$$

$\lambda = 20$  是**预先固定的收缩常量**，不是调出来的超参数： $E = 0$  时  $R$  退回训练期先验，  
 $E = 20$  时数据与先验各占一半。它没有在任何后置数据上搜索过。

**H2 只是用户总体历史状态**，不含 `user × tag`、`user × author` 或候选内容交互。  
因此 BL2 的成功支持"历史有信息"，**不支持"用户偏好某类内容"**——后者需要另建 H3 合同。

### 3.3 一个必须说明的前提

v010 保存了特征、预测、指标与 manifest，但**没有把训练完的模型权重写成文件**。  
后文 v011 / v012 所说的"从 sealed 暖启动"，实际加载的是事后从封存特征重新拟合复原的状态  
(`reconstructed_frozen_model_state.npz`，SHA-256 `c36c6bec...`)。

重建质量：概率的平均绝对差  $1.4 \times 10^{-8}$ 、最大差  $5.1 \times 10^{-7}$ 、相关系数 1。  
差异在 float32 容差之内，对任何指标的任何一位有效数字都不可见，**结论不受影响**。

写出来是因为：这次能补救，是因为特征矩阵恰好被保留了。  
**后续合同应把"模型权重必须落盘并进 artifact manifest"列为硬性输出要求。**

## 4. 怎么读这些数字

这一章回答：每个指标衡量什么、95% CI 是怎么算的、什么话不能从它推出来。

### 4.1 四个指标各管一件事

△ 一律是"候选模型 - 基线模型"，因此 AP / gAUC 为正较好，Log Loss / Brier 为负较好。

| 指标         | 它回答什么                                     | 常见误读                                           |
|------------|-------------------------------------------|------------------------------------------------|
| AP         | 全部事件按分数排序后，正例是否集中在前部（主排序指标）               | 受正例率影响，不能跨 prevalence 差异很大的切片裸比                |
| event-gAUC | <b>同一用户内</b> 正例是否通常得分高于负例，防止提升全来自用户间基础率差异 | 不等于线上曝光 slate 的排序表现                            |
| Log Loss   | 概率是否既正确又不过度自信（高置信错误重罚）                    | AP 好不保证 Log Loss 好—— <a href="#">§5.2</a> 就是反例 |
| Brier      | 预测概率离 0/1 标签的平方距离                         | 与 Log Loss 相关但不等价，应同时报告                        |

用 event-gAUC 而不是只看 pooled AP，是因为 Train 的 event-micro 正例率是 31.8944%，  
而 user-macro 平均率是 39.55%——**相差 7.65 个百分点**，活跃用户的权重足以改变总体判断。

## 4.2 95% CI 来自 2,000 次配对用户簇 bootstrap

它不是"95% 的单次预测会落在区间内", 而是:

- 1. 以**用户** (不是单条事件) 为重采样单位, 保留同一用户内事件的相关性;
- 2. 每个 bootstrap 样本上**同时重算 BL1 与 BL2**, 取同一批用户上的模型差值;
- 3. 取 2,000 个差值的 2.5% 与 97.5% 分位数。

所以"CI 不跨 0"只说明该**指定阶段、指定对比**下差异稳定, 不自动等价于跨域、线上或因果有效。

## 4.3 关于多重比较

本项目所有 95% CI 均为 per-comparison 区间, 未做 FWER / FDR 校正。

v010 涉及 3 阶段 × 4 指标, v011 涉及 3 个校准族, v012 涉及 3 个候选配置 × 7 个门。

项目对多重比较的控制手段是**预注册**——主指标、最小效应量、判据与选择规则在看到结果前已写入合同并冻结, 而不是事后从多个结果里挑显著的。这在设计上有效, 但不等价于统计校正。因此对 CI 下界贴近 0 的对比 (如 v012 的  $\Delta$ Brier 下界  $-0.0003$ ), 应按"单次预设检验的边缘证据"读。

# 5. 两次预实验：为什么是 Adam，为什么先失败一次

这一章回答：优化器怎么选的、以及一次"看起来很好"的早期结果为什么被拦下来了。

## 5.1 先证明"优化得够充分", 再比较科学结果

Adam / SGD 的比较**只在 Train-only 上进行**, 没有用任何后置标签。

方法是拿 CPU-LBFGS 求同一凸目标的高精度参考解  $\mathcal{L}_{\text{reference}}$ ,

要求 GPU 优化器满足

$$\text{regret} = \mathcal{L}_{\text{GPU}} - \mathcal{L}_{\text{reference}} \leq \max(10^{-4}, 0.005 |\mathcal{L}_{\text{reference}}|).$$

这里的 regret 是**优化目标缺口**, 不是用户体验 regret, 也不是强化学习 regret, 更不是 BL2 相对 BL1 的指标差。

| 优化器路线              | 冻结配置                                         | 通过 / 6 probes | 最大 regret           | 决策                          |
|--------------------|----------------------------------------------|---------------|---------------------|-----------------------------|
| GPU Adam           | $\eta = 0.03$ , 30 steps                     | 0 / 6         | 0.006750            | 不足                          |
| <b>GPU Adam</b>    | $\eta = 0.03$ , <b>100 steps</b>             | <b>6 / 6</b>  | <b>0.000540</b>     | <b>选中 (最小充分 checkpoint)</b> |
| GPU Adam           | $\eta = 0.03$ , 300 / 1,000 steps            | 6 / 6         | 0.000218 / 0.000040 | 更优但无理由超出预定                  |
| 全批 SGD, momentum=0 | $\eta \in [0.001, 0.1]$ , $\leq 3,000$ steps | 0 / 6         | 0.034773            | <b>冻结, 不进入后置评估</b>          |

最好的冻结 SGD ( $\eta = 0.1$ , 3,000 steps) 的 BL1 regret 是允许值的约 **12.7 倍**。  
把它带进 Validation，会把"历史带来什么"和"两个模型根本没被同等优化"混在一起。

"排除 SGD"不等于 SGD 证明历史无用，也不等于 Adam 科学上更优。  
它只说明原冻结 SGD 协议没达到进入后置评估的数值充分性。此后所有主张限定为 **GPU Adam 下**。

## 5.2 Gate 2B：有排序信号，但概率失败拦下了错误晋级

正式 GPU 验证前，Gate 2B 做了 7 天 Train rolling-origin 固定行回溯：

| 模型             | AP            | user-gAUC     | Log Loss      | Brier         |
|----------------|---------------|---------------|---------------|---------------|
| BL0 常数概率       | 0.3249        | 0.4984        | <b>0.6274</b> | <b>0.2178</b> |
| BL1 静态基线       | 0.3248        | 0.5019        | 5.1621        | 0.3203        |
| BL2 = BL1 + H2 | <b>0.4357</b> | <b>0.5239</b> | 4.2696        | 0.2758        |

BL2 - BL1 的  $\Delta AP = +0.1108$  [0.1015, 0.1204]，7/7 天为正——排序信号很强。  
但 BL1 / BL2 的绝对概率损失比"只报平均值"的 BL0 差了一个数量级，大量预测被裁剪在极端区间。

这个结果保留了"严格历史值得在健康协议下继续检验"的动机，  
却**拒绝**把它升级为概率模型、序列模型或 Validation 结论。  
后面三轮实验必须显式报告绝对概率门、概率健康、逐日稳定性与配对不确定性——  
根源就在这一步。

## 6. 三轮正式实验

这一章回答：每轮问了什么、冻结了什么、只改变了什么、结论到哪为止。

Train-only 粗筛与优化器充分性

↓ (Adam 冻结; Validation 解锁)

v010: H2 是否有离线排序增量?

↓ (发现 random 域基准率迁移: 31.9% → 8.4%)

v011: 冻结的排序在目标域能否得到可信概率?

↓ (校准后仍需检验受限适配的价值)

v012: 小幅、可回滚的目标域重训练能否再改善?

### 6.1 v010：H2 历史价值的三阶段确认

数据按 Validation → sealed standard → random audit 顺序开放，  
每一阶段完成并哈希复核后才解锁下一阶段。主分析用同目标行的 warm users，  
2,000 次配对用户簇 bootstrap 估计 CI (结果即图 1 上组)。

| 阶段         | 行数 / 用户       | $\Delta AP$                 | $\Delta event-gAUC$         | $\Delta Log Loss$             | $\Delta Brier$                | 逐日  |
|------------|---------------|-----------------------------|-----------------------------|-------------------------------|-------------------------------|-----|
| Validation | 886,452 / 902 | +0.0356<br>[0.0313, 0.0400] | +0.0385<br>[0.0349, 0.0419] | -0.0210<br>[-0.0229, -0.0191] | -0.0083<br>[-0.0091, -0.0075] | 4/4 |

| 阶段              | 行数 / 用户         | AP                          | event-gAUC                  | Log Loss                              | Brier                                 | 逐日     |
|-----------------|-----------------|-----------------------------|-----------------------------|---------------------------------------|---------------------------------------|--------|
| sealed standard | 4,401,690 / 974 | +0.0407<br>[0.0369, 0.0444] | +0.0462<br>[0.0434, 0.0490] | -0.0231<br>[-0.0248, -0.0215]         | -0.0090<br>[-0.0097, -0.0084]         | 17/17  |
| random audit    | 42,372 / 983    | +0.0262<br>[0.0183, 0.0347] | +0.0590<br>[0.0446, 0.0736] | -0.0096<br>[-0.0191, <b>+0.0001</b> ] | -0.0017<br>[-0.0057, <b>+0.0025</b> ] | 14 天为正 |

**random 阶段有两件必须同时读出的事，它们并不矛盾：**

- 1. **排序增量通过。**  $\Delta AP$  是最小效应 0.005 的约 5.2 倍，CI 下界 0.0183。
- 2. **绝对概率门未通过。** `final_claim_decision.json` 中 `absolute_probability_gate` 对 BL1 和 BL2 均为 `false`，`static_baseline_gate` 也是 `false`——两个模型的绝对概率健康都比冻结的 BL0 更差。通过的只有 `probability_saturation_gate`（没有大面积饱和）。

此外 random 阶段的  $\Delta \text{Log Loss}$  与  $\Delta \text{Brier}$  的 CI **跨 0**。  
这允许说“概率损失点估计方向改善”，**不允许说**“已被统计确定改善”。

表中的 4/4、17/17 是逐日  $\Delta AP$  为正的天数，用于发现单日反向退化，**不能代替 CI**——它们不是 4 次或 17 次独立重训。

## 6.2 v011：只修概率刻度，不碰排序

random 目标域的正例率约 8.4%，远低于 standard 训练期的约 31%–32%。  
冻结分数的排序可用，不等于它输出的 0.35 真代表 35% 概率。

**设计。** 目标域按时间切成 fit (8,731 行) → selection (10,544 行) → held-out (23,752 行)。  
候选校准器只在 fit 拟合、在 selection 选择，held-out 完全不参与任何选择。  
三个候选：M1 先验平移、M2 固定正斜率只拟合截距、M3 Platt 型双参数。  
M3 的 selection Log Loss 仅比 M2 低 0.000016，在冻结的 tie 规则下选更简单的 **M2**。

对冻结分数  $s_i$ ，形式统一为  $\hat{p}_i = \sigma(as_i + c)$ ，最终存档  $a = 1.0169043468$ 、 $c = -2.0952099481$ 。由于  $a > 0$ ，任意  $s_i > s_j$  仍得  $\hat{p}_i > \hat{p}_j$ ——**排序不变是硬门，不是副产品。**

## v011 目标域校准：概率刻度被修正，排序完全不动

校准前曲线远低于对角线（普遍高估）；校准后贴合对角线




图 3 是这轮最有说服力的证据。校准前（橙色）整条曲线远低于对角线——模型普遍高估；校准后（蓝色）贴合对角线。圆点面积正比于分箱样本量，可以看出绝大部分数据落在低概率区，两条曲线右端的抖动来自极小分箱。

| held-out 指标 (23,752 行 / 967 用户 / 2,063 正例) | 原始 BL2 | M2 校准后 | 差异 / 95% CI                |
|--------------------------------------------|--------|--------|----------------------------|
| AP                                         | 0.1977 | 0.1977 | 0 (排序精确不变)                 |
| event-gAUC                                 | 0.6236 | 0.6236 | 0 (排序精确不变)                 |
| Log Loss                                   | 0.5121 | 0.2689 | -0.2431 [-0.2586, -0.2268] |

| held-out 指标 (23,752 行 / 967 用户 / 2,063 正例) | 原始 BL2 | M2 校准后 | 差异 / 95% CI                |
|--------------------------------------------|--------|--------|----------------------------|
| Brier                                      | 0.1700 | 0.0748 | -0.0952 [-0.1022, -0.0880] |
| ECE20                                      | 0.2813 | 0.0067 | —                          |
| 平均预测概率                                     | 0.3682 | 0.0823 | 真正正例率为 0.0869              |

**结论：**在这一 post-audit 目标域测试中，独立校准让概率可信得多，且完全不触碰排序。它不改变 v010 的历史价值结论，也不会把 v010 的 random audit 变回 untouched。

### 6.3 v012：受 tether 约束的目标域适配

v011 只改概率映射，理论上不可能提高 AP。若目标域的特征—标签关系也变了，就需要检验有限度重训练是否有增量。但小样本上自由重训会遗忘 sealed 模型、追逐噪声，因此加 tether 把参数拉回冻结解：

$$\mathcal{L}_{v012} = -\frac{1}{n} \sum_i [y_i \log \sigma(s_i) + (1 - y_i) \log(1 - \sigma(s_i))] + \frac{\tau}{2} \|\mathbf{w} - \mathbf{w}_{\text{sealed}}\|_2^2.$$

截距不受 tether（允许适应目标域基准率），之后再在独立段做概率校准——把这“排序结构的适配”和“平均概率的修正”分开了。  
三个候选全部通过 eligibility，按冻结规则选中 `c2_balanced` ( $\eta = 0.01$ 、100 steps、 $\tau = 0.001$ )。

最终回放（12,399 行 / 857 用户 / 1,039 正例，真正正例率 0.0838）：

| 模型                               | AP            | event-gAUC    | Log Loss      | Brier         | ECE20  | 平均 $\hat{p}$ |
|----------------------------------|---------------|---------------|---------------|---------------|--------|--------------|
| TARGET_BL0                       | 0.0838        | 0.5000        | 0.2880        | 0.0768        | 0.0030 | 0.0808       |
| OLD_BL2 + v011                   | 0.1879        | 0.6214        | 0.2639        | 0.0728        | 0.0066 | 0.0816       |
| NEW_BL1（适配后无历史）                  | 0.1765        | 0.6139        | 0.2693        | 0.0736        | 0.0069 | 0.0775       |
| <b>NEW_BL2 + v012 calibrator</b> | <b>0.2049</b> | <b>0.6455</b> | <b>0.2606</b> | <b>0.0721</b> | 0.0062 | 0.0797       |


两个关键的同目标行配对对比：

| 对比                                  | 它回答什么          | $\Delta$ AP              | $\Delta$ Log Loss          |
|-------------------------------------|----------------|--------------------------|----------------------------|
| <code>NEW_BL2 - OLD_BL2+v011</code> | 重训练相对旧候选还值不值   | +0.0170 [0.0053, 0.0313] | -0.0033 [-0.0051, -0.0017] |
| <code>NEW_BL2 - NEW_BL1</code>      | 适配之后 H2 是否仍有增量 | +0.0285 [0.0152, 0.0418] | -0.0087 [-0.0114, -0.0061] |

全部必需门通过，科学状态 `retraining_adds_value`，  
工程建议 `deploy_NEW_BL2_with_v012_calibrator_pending_new_data_confirmation`。

## v012 最终回放：3/3 天为正，但增量在三天内衰减至接近 0

预注册门槛为「至少 2 天为正」——门通过了，趋势值得单独记录



逐日值未做 bootstrap，无置信区间；每日仅约 4,000 行、320-370 正例，单日噪声大。  
三点不足以拟合衰减率，但方向与目标域适配的机制预期一致——新数据确认应使用更长回放窗口。

**图 4 记录了一个汇总数字掩盖的事实。** `positive_history_AP_days: 3` (门槛  $\geq 2$ ) 是通过的门，但逐日  $\Delta AP$  在三天内从 +0.0322 衰减到 +0.0041。适配窗口的最后一天是 04-29，三个回放日距适配时点分别是 7、8、9 天。

两面都要说：

- **不能过度解读。** 每天只有约 4,000 行、320-370 正例，单日 AP 噪声很大；逐日值**没有做 bootstrap**，**没有 CI**，三个点不足以拟合衰减率。池化的 +0.0170 [0.0053, 0.0313] 仍是该段主结论。
- **也不能忽略。** 方向与目标域适配的机制预期一致：适配学到的是“适配窗口附近”的关系，距离越远越失效。它直接决定部署时的 **retrain 频率**。

因此新数据确认应包含**足够长的回放窗口**（不是 3 天），并预注册“逐日增量对 time-since-adaptation 的回归”作为次要终点。

## 6.4 一个必须带上的限制

`cat_user` (用户 one-hot) 在特征集内。v012 的适配在 760 个用户上更新了含用户维度的权重，而最终回放评估的 857 个用户与之高度重叠。

这在时点上完全合法（无未来泄漏），但意味着 `NEW_BL2 - OLD_BL2 + v011` 的增量中

**含有用户级适配成分**——新用户 / 冷启动用户不会获得同等收益。

相对干净的对照是 `NEW_BL2 - NEW_BL1 = +0.0285 [0.0152, 0.0418]` (两者被同样适配过)。

## 7. 可以说与不能说

## 7.1 为什么不能把三轮指标合并

v010 的三个阶段覆盖不同时间与曝光域；v011 / v012 是同一 random 域上的 post-audit 切分，且如 [§2.2](#) 所述**共享数据**。因此不存在一个"总置信区间"，也不能说 v012 推翻或替代了 v010。正确的读法是逐条命题：

| 证据链                      | 验证的命题                           | 状态                     |
|--------------------------|---------------------------------|------------------------|
| v010 Validation → sealed | H2 是否在两个连续 standard 时间窗稳定提高离线预测 | 支持                     |
| v010 random audit        | 冻结的 H2 排序增量能否迁移到 random 曝光      | 支持；绝对概率不可直接部署          |
| v011                     | 目标域能否不改排序而修复概率刻度                | 支持 (post-audit)        |
| v012                     | 受约束适配能否比旧 BL2+校准再加价值            | 支持 (post-audit replay) |

## 7.2 对照表

| ✅ 可以说                                                    | ❌ 不能说                                  |
|----------------------------------------------------------|----------------------------------------|
| 冻结 GPU Adam 下，H2 严格用户历史相对同静态基线有稳定的离线排序增量                 | 模型已证明线上观看时长、留存或商业指标提升                  |
| 该增量在 standard 与 random exposure 审计中都出现                   | random 覆盖任意策略、全平台候选池，或可做无假设精确 OPE      |
| v011 校准在 post-audit 目标域修复概率质量且严格保序                       | v011 是 untouched random audit 或全新的确认试验 |
| v012 在最终回放中同时提升排序与概率                                     | v012 已完成新数据确认，可无审批上线                   |
| <code>NEW_BL2 + v012 calibrator</code> 是当前最强 <b>工程候选</b> | Adam 之外的优化器同样稳健；原 SGD 已被证明失败或成功        |
| H2 是用户 <b>总体</b> 历史状态                                    | H2 证明用户喜欢某标签 / 作者 / 内容语义（需 H3 交互合同）    |
| v013 已登记神经序列设计与 5-seed 门                                 | Gold、神经序列训练或新标签访问已获授权或完成               |

## 7.3 部署姿态

若做工程试运行，把 `NEW_BL2 + v012 calibrator` 当作**可回滚候选**：  
保留 BL1 / BL0 回退路径，监控曝光域、历史深度、warm/cold video、duration-valid 状态、AP 代理指标与概率健康，并按 [§6.3](#) 的衰减迹象设定重训周期。

若做科学机制，另建 H3（用户 × 作者/标签/内容）增量合同，以当前 BL2 为固定基线；  
**不能把 H2 的成功改写为内容偏好结论。**

## 8. 下一步

### 8.1 新数据确认：先认清它做不了什么

`pending_new_data_confirmation` 不是"还差最后一步跑一下"。  
random 域已 100% 消耗 (图 2)，任何再切分都是重用已参与过拟合或选择的行，  
产出的将是第四次 post-audit replay，而不是确认性证据。合法路径只有两条：

| 路径                                         | 需要先做什么                                                                                                          |
|--------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| A. 换数据集 (KuaiRand-Pure / 27K 的独立 random 域) | 新数据合同、Silver 清洗，以及 <code>cat_user</code> / <code>cat_video</code> 的跨数据集映射策略—— <b>用户与视频 ID 不通用，词典要重建，这是主要工程量</b> |
| B. 新日志 (真实线上新时间窗)                          | 数据获取授权                                                                                                          |

C. 在 late-standard 的未使用日期上做时间外确认 —— **已排除**：  
sealed v008 的 `daily_metrics.csv` 覆盖 2022-04-22 至 05-08 全部 17 天，该域没有未使用日期。

### 8.2 建议优先做的实验：BL1+ 画像列消融

当前 BL1 的用户侧信息只有 `cat_user`，`user_features_1k.csv` 的 30 列画像**完全没进模型**。  
因此存在一个可被攻击的替代解释：v010 证明的可能是  
"用户基准率的时变估计优于用户 ID 的静态记忆"，而不是"严格历史有独立价值"。

这个消融**不需要任何新的数据访问授权**——用 Gate 2B 的 Train-only rolling-origin 即可，  
不触碰 Validation / sealed / random。代码与数据现成，GPU 约 1-2 小时。  
真正的前置是一次特征可用性裁定：那 30 列的采集时点未逐列证明，  
需先在 `configs/feature_availability_v002.yaml` 中判定哪些可作静态特征、哪些只能作诊断。

**建议排在 v013 神经序列之前**——v013 需先物化正式 Gold，前置很重；  
这个消融约 2 天就能把 v010 的核心结论加固一档。

### 8.3 其他

- 1. **不重洗、不覆盖**：保持 Raw、Silver 与 v010-v012 的路径、合同和哈希产物不变。
- 2. **正式 Gold**：如需序列模型，先批准 Gold 合同、`sample_id`、allowlist/denylist、  
时间线复算与 manifests。**本报告不能代替 Gold。**
- 3. **Agent 集成**：先生成独立的消费侧 Evidence manifest 与 digest pinning，  
在证据与批准齐备前保持 fail-closed。细节见完整档案 §11。

## 附录 A 术语速查

| 术语          | 一句话                            | 详见   |
|-------------|--------------------------------|------|
| gate (门)    | 预注册的通过判据；结果出来前就冻结，不事后调整        | §4.3 |
| eligibility | 候选进入正式比较前必须满足的准入条件（如排序不变、概率健康） | §6.2 |

| 术语                     | 一句话                                                                                                      | 详见            |
|------------------------|----------------------------------------------------------------------------------------------------------|---------------|
| regret                 | 优化目标缺口 $\mathcal{L}_{\text{GPU}} - \mathcal{L}_{\text{reference}}$ 。不是用户体验 regret，不是强化学习 regret，不是模型间指标差 | §5.1          |
| tether                 | 重训练时把参数拉回冻结解的 L2 惩罚，强度 $\tau$                                                                            | §6.3          |
| warm start (暖启动)       | 从已冻结模型的权重开始训练，而非随机初始化                                                                                    | §3.3、<br>§6.3 |
| post-audit             | 在主结论冻结之后、用同一数据域做的补充验证。证据等级低于 pristine confirmation                                                       | §6.2、<br>§6.3 |
| pristine confirmation  | 在从未被任何拟合或选择触碰过的数据上做的确认性试验                                                                                | §8.1          |
| sealed                 | 配置冻结后一次性打开的时间外测试域                                                                                        | §6.1          |
| Gold-equivalent        | 满足 Gold 设计规则、但未作为正式版本化数据层发布的实验级特征矩阵                                                                      | §8.3          |
| event-gAUC / user-gAUC | 先在每个用户内算 AUC 再加权平均；前者按事件数加权，后者按用户等权                                                                      | §4.1          |
| canonical model view   | Silver 事件行 U 与其身份键不重叠的同源公式疑点行（仍用官方标签）                                                                    | §2.1          |

## 附录 B 证据索引

本报告不产生新实验结论；所有数值均来自下列哈希化制品。  
完整的逐条链接见 [完整档案 §12.2](#)。

| 编号  | 入口                               | 内容                                    |
|-----|----------------------------------|---------------------------------------|
| E1  | <a href="#">Silver 清洗报告</a>      | 行数对账、质量规则、标签率与验收门                     |
| E2  | <a href="#">Train-only 关联报告</a>  | 粗筛、分布与假设收敛                            |
| E3  | <a href="#">Gate 2B 基线结果</a>     | 早期排序信号与绝对概率失败 (§5.2)                  |
| E4  | <a href="#">GPU 优化器预检</a>        | Adam / SGD objective-regret 对比 (§5.1) |
| E5  | <a href="#">v010 最终证据总结</a>      | 三阶段主结论与边界 (§6.1)                      |
| E6  | <a href="#">v010 random 最终判定</a> | 各门的机器判定，含两个 false                     |
| E7  | <a href="#">v011 结果 · 判定</a>     | 目标域校准 (§6.2)                          |
| E8  | <a href="#">v012 结果 · 判定</a>     | 受约束重训练与最终回放 (§6.3)                    |
| E9  | <a href="#">sealed 模型重建诊断</a>    | 重建权重的数值等价性 (§3.3)                     |
| E10 | <a href="#">GPU 导入与状态对账</a>      | 文件级完整性与当前 Silver 一致性                  |

| 编号  | 入口                             | 内容                           |
|-----|--------------------------------|------------------------------|
| E11 | <a href="#">完整性勘误</a>          | 证据核验记录与刻意披露的事实               |
| E12 | <a href="#">预测标签、模型公式与设计由来</a> | BL0/BL1/BL2、校准与 tether 的详细推导 |
| E13 | <a href="#">项目交接</a>           | 数据合同、清洗边界、Gold 设计与禁止事项       |

图表资产：figures/，由 [kuairand-longseq-agent/scripts/render\\_report\\_figures\\_v001.py](#)

从上述制品的 CSV 直接生成，**不重新计算任何指标**。重跑：

```
python kuairand-longseq-agent/scripts/render_report_figures_v001.py \  
  --package-root . --out figures
```

## 本报告自身的验证边界

本文未读取或修改 Raw 数据、未运行模型、未修改 Silver、未修改任何已发布的分析报告或哈希产物。  
四张图由既有 CSV 制品渲染，不产生新指标。正文数值统一保留 4 位小数以匹配 bootstrap 不确定度量级；  
全精度值以各阶段 `pooled_metrics.csv`、`paired_user_cluster_bootstrap.csv` 与 `final_decision.json` 为准。